

1. 인공 신경망의 한계와 딥러닝 출현

- 퍼셉트론

딥러닝 신경망의 기원이 되는 알고리즘.

- AND 게이트 : 입력 모두가 1 일 때만 작동
- OR 게이트 : 입력 중 하나라도 1이면 작동
- XOR 게이트 : 입력 2개 중 1개가 1일 때 작동


단층 퍼셉트론(입력층과 출력층만 있는 퍼셉트론)에서 학습이 불가능. 따라서 입력층과 출력층 사이 중간층(은닉층)을 두어 해결

- 심층 신경망(Deep Neural Network, DNN)

입력층과 출력층 사이 은닉층이 여러 개 있는 신경망

4.2 딥러닝 구조

딥러닝 용어




- 입력층, 출력층, 은닉층

구분	구성 요소	설명
층	입력층(input layer)	데이터를 받아들이는 층
	은닉층(hidden layer)	모든 입력 노드부터 입력 값을 받아 가중합을 계산하고, 이 값을 활성화 함수에 적용하여 출력층에 전달하는 층
	출력층(output layer)	신경망의 최종 결과값이 포함된 층

- 가중치

입력 값이 연산 결과에 미치는 영향력을 조절.



가중치가 매우 작으면 가중치를 곱한 값은 0에 가까워질 수 있다.

- 가중합(전달 함수)

각 노드에서 들어오는 신호에 가중치를 곱해서 다음 노드로 전달되는데, 이 값들을 모두 더한 합계.


- 활성화 함수

전달 함수에서 전달받은 값을 출력할 때 일정 기누에 따라 출력 값을 변화시키는 비선형 함수.

- 시그모이드 함수

선형 함수의 결과를 0~1 사이의 비선형 형태로 변환해 줌. 모델의 깊이가 깊어지면 기울기가 사라지는 '기울기 소멸 문제'로 인해 딥러닝 모델에는 잘 사용하지 않는다.


♥ 그림 4-8 시그모이드 활성화 함수와 미분 결과



○ 하이퍼볼릭 탄젠트 함수

선형 함수의 결과를 -1~1 사이에서 비선형 형태로 변형. 시그모이드 함수에서 결과의 평균이 0이 아닌 양수로 편향된 문제를 해결하지만, 기울기 소멸 문제는 여전히 존재


♥ 그림 4-9 하이퍼볼릭 탄젠트 활성화 함수와 미분 결과



○ 렐루(RELU) 함수


입력이 음수일 때는 0을 출력, 양수일 때는 x 를 출력하는 방식. 경사 하강법에 영향을 주지 않아 학습 속도가 빠르고, 기울기 소멸 문제를 해결할 수 있다. 음수 값을 입력받으면 항상 0을 출력하기 때문에 학습 능력이 감소하는 문제가 있음.

♥ 그림 4-10 렐루 활성화 함수와 미분 결과



○ 리키 렐루(Leaky Relu) 함수

입력값이 음수이면 0.001 과 같은 매우 작은 수를 반환. 입력값이 수렴하는 구간이 제거되어 렐루 함수의 학습 능력 감소 문제 해결 가능.



◦ 소프트맥스 함수

입력 값을 0~1 사이에 출력되도록 정규화하여 출력 값의 총합이 항상 1이 되도록 함

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

• 손실 함수

학습을 통해 얻은 데이터의 추정치가 실제 데이터와 얼마나 차이가 나는지 평가하는 지표. 경사 하강법에서 오차를 구할 때 사용한다.

◦ 평균 제곱 오차(MSE)

실제 값과 예측 값의 차이를 제곱하여 평균을 낸 것.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$\hat{y}_i$: 신경망의 출력(신경망이 추정한 값)
 y_i : 정답 레이블
 i : 데이터의 차원 개수

◦ 크로스 엔트로피 오차(CEE)

분류 문제에서 원-핫 인코딩 했을 때 사용할 수 있는 오차.


$$CrossEntropy = - \sum_{i=1}^n y_i \log \hat{y}_i$$

$\hat{y}_i$: 신경망의 출력(신경망이 추정한 값)
 y_i : 정답 레이블
 i : 데이터의 차원 개수

딥러닝 학습

순전파와 역전파

▼ 그림 4-12 순전파와 역전파




- 순전파(feedforward)

모든 뉴런이 이전 층의 뉴런에서 수신한 정보에 변환(가중합 및 활성화 함수)를 적용하여 다음 층의 뉴런으로 전송.

- 역전파(backpropagation)

최종 층에 도달한 예측 값과 실제 값의 차이(손실/오차) 를 추정하고, 이 손실 정보를 역으로 전파(출력→은닉→입력) 하며 가중치를 업데이트.


딥러닝의 문제점과 해결 방안



딥러닝은 많은 은닉층을 가질 수록 데이터 분류가 잘 되는 경향성을 가진다. 하지만 은닉층이 많을수록 몇 가지 문제점을 가짐.

1. 과적합(over-fitting) 문제


훈련 데이터를 과하게 학습해서 새로운 데이터(실제 데이터) 에 대한 오차가 높아지는 경우.



- 드롭아웃(dropout)

학습 과정 중 일부 노드를 학습에서 제외시켜 과적합 방

▼ 그림 4-15 일반적인 신경망과 드롭아웃이 적용된 신경망



2. 기울기 소멸 문제

역전파 과정에서 출력층 → 은닉층으로 전달되는 오차가 크게 줄어들어 학습이 되지 않는 현상. 렐루 활성화 함수를 사용하여 해결할 수 있다.

3. 성능 악화 문제

경사 하강법은 손실 함수의 비용이 최소가 되는 지점을 찾을 때까지 기울기가 낮은 쪽으로 계속 이동시키는 과정을 반복하는데, 이때 성능이 나빠지는 문제가 발생한다.


- 배치 경사 하강법

전체 데이터셋에 대한 오류를 구한 후 기울기를 한 번만 계산하여 모델의 파라미터 업데이트. 한 스텝에 모든 데이터셋을 이용하므로 학습이 오래 걸림

- 미니 배치 경사 하강법

전체 데이터셋을 미니 배치 여러 개로 나누고, 미니 배치 한 개마다 기울기를 구한 후 그것의 평균 기울기를 이용하여 모델을 업데이트.

▼ 그림 4-20 미니 배치 경사 하강법



- 확률적 경사 하강법

임의로 선택한 데이터에 대해 기울기를 계산. 파라미터 변경 폭이 불안전하고 정확도가 낮을 수 있음.

- **옵티마이저** : 확률적 경사 하강법의 파라미터 변경 폭이 불완전한 단점을 해결하기 위해 사용

- 속도 조절

- 아다그리드(Adagrad) : 변수의 업데이트 횟수에 따라 학습률을 조정
G 함수 : 파라미터마다 다른 학습률을 주기 위해 사용. 기울기가 커짐에 따라 G 값이 커져서 학습률은 작아짐.

$$w(i+1) = w(i) - \frac{\eta}{\sqrt{G(i)+\epsilon}} \nabla E(w(i))$$

$$G(i) = G(i-1) + (\nabla E(w(i)))^2$$

- 아다델타(Adadelata) : 아다그리드에서 G값이 커짐에 따라 학습이 멈추는 문제를 해결.

D함수 : 가중치의 변화량 크기를 누적한 값

$$w(i+1) = w(i) - \frac{\eta}{\sqrt{D(i-1)+\epsilon}} \nabla E(w(i))$$

$$G(i) = \gamma G(i-1) + (1-\gamma)(\nabla E(w(i)))^2$$

$$D(i) = \gamma D(i-1) + (1-\gamma)(\Delta(w(i)))^2$$

- 알엠에스프롭(RMSProp) : 아다그리드의 G(i) 값이 무한히 커지는 문제 해결

사용자가 감마 값을 저절하여 학습률 크기를 비율로 조절할 수 있다.

$$w(i+1) = w(i) - \frac{\eta}{\sqrt{G(i)+\epsilon}} \nabla E(w(i))$$

$$G(i) = \gamma G(i-1) + (1-\gamma)(\nabla E(w(i)))^2$$

- 운동량 조절

- 모멘텀(Momentum)

가중치를 수정하기 전에 이전 수정 방향을 참고하여 같은 방향으로 일정한 비율만 수정하는 방법. SGD 와 함께 사용한다.

- 네스테로프 모멘텀(Nesterov Accelerated Gradient, NAG)

기존 모멘텀과 달리 모멘텀 값이 적용된 지점에서 기울기 값을 계산. 모멘텀 방식의 빠른 이동 속도는 그대로 가져가면서 멈추어야 할 적절한 시점에 제동을 거는 데 훨씬 용이.

딥러닝을 사용할 때 이점

특성 추출

컴퓨터가 분석할 수 있도록 사람이 인지하는 데이터를 컴퓨터가 인지할 수 있는 형태(벡터)로 변환해 주는 과정

- 딥러닝 이전의 특성 추출


머신 러닝 알고리즘인 SVM, 나이브 베이즈, 로지스틱 회귀의 특성 추출은 매우 복잡하며 수집된 데이터에 대한 전문지식 필요.

- 딥러닝


특성 추출 과정을 알고리즘에 통합시킴

딥러닝 알고리즘

심층 신경망(DNN)




합성곱 신경망(CNN)



합성곱층(convolutional layer) 과 풀링층(pooling layer) 를 포함하는 이미지 처리 성능이 좋은 인공 신경망 알고리즘 ex) LeNet-5, AlexNet, VGG, GoogLeNet, ResNet 등

- 각 층의 입출력 형상 유지
- 이미지의 공간 정보를 유지하면서 인접 이미지와 차이가 있는 특징을 효과적으로 인식
- 복수의 필터로 이미지의 특징을 추출, 학습
- 풀링층 - 추출한 이미지의 특징을 모으고 강화
- 필터를 공유 파라미터로 사용해서 학습 파라미터가 매우 적음

순환 신경망(RNN)



시계열 데이터 같은 시간 흐름에 따라 변화하는 데이터를 학습하기 위한 인공 신경망. 자연어 처리 분야에 많이 사용한다.

- 순환 신경망의 기울기 소멸 문제를 해결하고자 LSTM 을 사용하고는 함.


제한된 볼츠만 머신

가시층과 은닉층으로 구성된 모델. 가시층은 은닉층과만 연결된다. (가시층-가시층 연결이나 은닉층-은닉층 연결은 불가능)

- 차원 감소, 분류, 선형 회귀 분석, 협업 필터링, 특성 값 학습, 주제 모델링
- 기울기 소멸 문제 해결을 위한 사전 학습 용도
- 심층 신뢰 신경망(DNN)의 요소로 활용

심층 신뢰 신경망(DBN)

제한된 볼츠만 머신을 블록처럼 여러 층으로 쌓은 형태로 연결된 신경망. 레이블이 없는 데이터에 대한 비지도 학습 가능.



- 순차적으로 심층 신뢰 신경망을 학습시켜 가면서 계층적 구조 생성
- 비지도 학습으로 학습
- 위로 올라갈수록 추상적 특징을 추출
- 학습된 가중치를 다층 퍼셉트론의 가중치 초기값으로 사용