

2주차 스터디

교재 : 딥러닝 파이토치 교과서

분량 : 4장

과제 기간 : ~2025-03-17


4장 - 딥러닝 시작

[4.1 인공 신경망의 한계와 딥러닝 출현]

퍼셉트론 :

다수의 신호(흐름이 있는)를 입력으로 받아 하나의 신호를 출력

이 신호를 입력으로 받아 '흐른다/안흐른다(0 또는 1)'는 정보를 앞으로 전달하는 원리로 작동한다




퍼셉트론의 원리

위 그림과 같이, 두 개의 입력이 있을 때 컴퓨터가 논리적으로 인식하는 방법을 알아보자

1. AND 게이트

모든 입력이 '1'일 때 작동 (= 입력 중 하나라도 '0'을 갖는다면 작동을 멈춤)


x_1	x_2	y
0	0	0
1	0	0
0	1	0
1	1	1



2. OR 게이트

둘 중 하나만 '1'이거나, 둘 다 '1'일 때 작동 (= 입력 모두가 0인 경우를 제외한 모든 경우')


x_1	x_2	y
0	0	0
1	0	1
0	1	1
1	1	1



3. XOR 게이트

배타적 논리합, 입력 두 개 중 한 개만 '1'일 때 작동

x_1	x_2	y
0	0	0
1	0	1
0	1	1
1	1	0



XOR 게이트는 데이터가 비선형적으로 분리되기 때문에, 제대로 된 분류가 어렵다

⇒ 즉 단층 퍼셉트론에서 XOR 학습이 불가능하다

이를 극복하는 방안으로 입력층과 출력층 사이에 하나 이상의 중간층(은닉층)을 두어 비선형적으로 분리되는 데이터에 대해서도 학습이 가능하도록 다층 퍼셉트론(multi-layer perceptron)을 고안함

은닉층이 여러 개 있는 신경망 → **심층 신경망(Deep Neural Network)**

심층 신경망을 다른 이름으로 "**딥러닝**"이라고 한다.

[4.2 딥러닝 구조]

딥러닝 :


- 여러 층을 가진 인공 신경망을 사용하여 학습을 수행하는 것
- 각 층은 어떻게 구성되고, 역할이 무엇인지, 딥러닝 용어는 무엇인지 살펴보자

[4.2.1 딥러닝 용어]

딥러닝은 다음 그림과 같이

1. 입력층
2. 출력층
3. 두 개 이상의 은닉층
4. 입력 신호를 전달하기 위한 다양한 함수

등으로 구성되어 있다.



구분	구성 요소	설명
층	입력층(input layer)	데이터를 받아들이는 층
	은닉층(hidden layer)	모든 입력 노드부터 입력 값을 받아 가중합을 계산하고, 이 값을 활성화 함수에 적용하여 출력층에 전달하는 층
	출력층(output layer)	신경망의 최종 결과값이 포함된 층


구분	구성 요소	설명
가중치(weight)		노드와 노드 간 연결 강도
바이어스(bias)		가중합에 더해 주는 상수로, 하나의 뉴런에서 활성화 함수를 거쳐 최종적으로 출력되는 값을 조절하는 역할을 함
가중합(weighted sum), 전달 함수		가중치와 신호의 곱을 합한 것
함수	활성화 함수(activation function)	신호를 입력받아 이를 적절히 처리하여 출력해 주는 함수
	손실 함수(loss function)	가중치 학습을 위해 출력 함수의 결과와 실제 값 간의 오차를 측정하는 함수

• 가중치

입력 값이 연산 결과에 미치는 영향력을 조절하는 요소

w_1 값이 0, 혹은 0과 가까운 값이라면 연산 결과인 x_1w_1 값은 0이거나 0에 가까운 값이 된다

→ 입력 값의 연산 결과를 조정하는 역할을 하는 것이 가중치이다




- **가중합 또는 전달 함수**

가중합은 전달 함수라고 한다

각 노드에서 들어오는 신호에 가중치를 곱해 다음 노드로 전달된다 → 이 값들을 모두 더한 합계를 **가중합**이라고 한다

가중합을 활성화 함수로 보내기 때문에 전달 함수(transfer function)라고도 한다



전달 함수

$$\sum_i w_i x_i + b$$

(w : 가중치, b : 바이어스)

가중합 계산 공식

- **활성화 함수**

전달 함수에서 전달받은 값을 출력할 때, **일정 기준에 따라 출력 값을 변화시키는 비선형 함수**를 의미한다

종류 : sigmoid, hyperbolic tangent, ReLU 함수, softmax 등

- 1. 시그모이드 함수**

선형 함수의 결과를 **0~1 사이에서 비선형 형태로 변형**해준다


주로 **로지스틱 회귀 등의 분류 문제**를 확률적으로 표현하는데 사용된다

기울기 소멸 문제가 발생해서 딥러닝 모델에서는 잘 사용하지 않는다

*기울기 소멸 문제 : 활성화 함수 계산 과정에서 도함수 값이 계속 곱해지면서 가중치 결과값이 0이 되어 더 이상 계산이 불가능한 상태를 의미

$$f(x) = \frac{1}{1 + e^{-x}}$$

시그모이드 함수 수식




시그모이드 활성화 함수와 미분 결과

- 2. 하이퍼볼릭 탄젠트 함수**

선형 함수의 결과를 **-1~1 사이에서 비선형 형태로 변형**해준다

시그모이드에서 결과값의 평균이 0이 아닌 양수로 편향된 문제를 해결하지만 여전히 기울기 소멸 문제 발생



3. 렐루 함수


입력이 음수일 때는 0을 출력하고 양수일 때는 x를 출력

경사 하강법에 영향을 주지 않아 학습 속도가 빠르고 기울기 소멸 문제가 발생하지 않는다

일반적으로 은닉층에서 사용하며 하이퍼볼릭 탄젠트 함수보다 학습 속도가 6배 빠르다

음수 값을 입력 받으면 항상 0을 출력해 학습 능력이 감소한다

→ 리키 렐루(Leaky ReLU) 함수로 문제 해결



4. 리키 렐루 함수

입력 값이 음수면 0과 가까운 매우 작은 수를 반환한다

입력 값이 수렴하는 구간(=음수를 입력했을 때 0이 출력되는 렐루 함수의 구간)이 제거되어 렐루 함수를 사용할 때 생기는 문제를 해결할 수 있다

5. 소프트맥스 함수

입력 값을 0~1 사이에 출력되도록 정규화하여 출력 값들의 총합이 항상 1이 되도록 한다

딥러닝에서 출력 노드의 활성화 함수로 많이 사용한다

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

소프트맥스 함수 수식 / $\exp(x)$: 지수 함수, n : 출력층의 뉴런 개수, y_k : k 번째 출력

소프트맥스 함수의 분자 : 입력 신호 a_k 의 지수 함수 / 분모 : 모든 입력 신호의 지수 함수 합

- **손실 함수**

경사 하강법 : 학습률과 손실 함수의 순간 기울기를 이용하여 가중치를 업데이트 하는 방법

→ 미분의 기울기를 이용해 **오차를 비교하고 최소화하는 방향으로 이동**시키는 방법
이 때의 오차를 구하는 방법을 **손실함수**라고 한다

손실 함수 : 학습을 통해 얻은 데이터의 추정치가 실제 데이터와 얼마나 차이가 나는지 평가하는 지표

클수록 많이 틀렸다, 0에 가까우면 완벽하게 추정할 수 있다는 의미

종류 : Mean Squared Error(MSE), Cross Entropy Error(CEE) 등이 있다

1. 평균 제곱 오차(MSE)

실제 값과 예측 값의 차이(error)를 제곱하여 평균을 낸 것

MSE 값이 작을수록 예측력이 좋은 것을 의미

회귀에서 손실 함수로 주로 사용된다

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

MSE 수식

2. 크로스 엔트로피 오차(CEE)

분류 문제에서 원-핫 인코딩을 했을 때만 사용할 수 있는 오차 계산법

*원-핫 인코딩 : 단어 집합의 크기를 벡터 차원으로 하고 표현하고 싶은 단어의 인덱스에 1 값을 부여한 후, 다른 인덱스에는 0을 부여하는 단어의 벡터 표현 방식


경사 하강법 과정에서 학습이 지역 최소점에서 멈출 수 있다 → 방지하기 위해 자연 상수 e에 반대되는 자연 로그를 모델의 출력 값에 취한다

$$CrossEntropy = - \sum_{i=1}^n y_i \log \hat{y}_i$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

[4.2.2 딥러닝 학습]

딥러닝 학습은 크게 **순전파**와 **역전파**라는 두 단계로 진행된다



• 순전파 (feedforward)

- 네트워크에 훈련 데이터가 들어올 때 발생
- 데이터를 기반으로 예측 값을 계산하기 위해 전체 신경망을 교차해 나감
⇒ 모든 뉴런이 이전 층의 뉴런에서 수신한 정보에 변환(가중합 및 활성화 함수)을 적용하여 다음 층(은닉층)의 뉴런으로 전달하는 방식

1. 네트워크를 통해 입력 데이터 전달
2. 데이터가 모든 층을 통과하고 모든 뉴런이 계산을 완료하면 예측값은 최종 층(출력층)에 도달
3. 손실 함수로 네트워크의 예측 값, 실제 값의 차이(손실, 오차)를 추정

**이때 손실 함수 비용은 0이 이상적

**손실 함수 비용이 0에 가깝도록 하기 위해 모델이 훈련을 반복하면서 가중치를 조정

• 역전파 (backpropagation)


- 손실(오차)이 계산되면 정보는 역으로 전파
출력층 → 은닉층 → 입력층

- 예측 값과 실제 값 차이를 각 뉴런의 가중치로 미분한 후 기존 가중치 값에서 뺄
- **이 과정을 출력층 → 은닉층 → 입력층 순서로 모든 뉴런에 대해 진행
- **계산된 각 뉴런 결과를 또다시 순전파의 가중치 값으로 사용

[4.2.3 딥러닝의 문제점과 해결 방안]

딥러닝의 핵심 : 활성화 함수가 적용된 여러 은닉층을 결합해 비선형 영역을 표현하는 것

다음 이미지를 보면 은닉층 개수가 많을수록 데이터 분류가 잘 되고 있음을 볼 수 있다



은닉층의 개수가 분류에 미치는 영향

은닉층의 개수가 많을수록 다음 세 가지 문제점이 생긴다

1. 과적합 문제 발생


과적합(over-fitting) : 훈련 데이터를 과하게 학습해서 발생

**훈련 데이터가 실제 데이터의 일부분

**훈련 데이터를 과하게 학습했기 때문에 예측 값과 실제 값 차이인 오차가 감소하지만, 검증 데이터에 대해서는 오차가 증가

훈련 데이터에 대해 과하게 학습하여 실제 데이터에 대한 오차가 증가하는 현상

♥ 그림 4-14 과적합




해결 방법 : 드롭아웃(dropout)

신경망 모델이 과적합되는 것을 피하는 방법

학습 과정 중 임의로 일부 노드를 학습에서 제외시킴

♥ 그림 4-15 일반적인 신경망과 드롭아웃이 적용된 신경망




2. 기울기 소멸 문제 발생

은닉층이 많은 신경망에서 주로 발생

출력층에서 은닉층으로 전달되는 **오차가 크게 줄어들어 학습이 되지 않는** 현상을 의미

→ 기울기가 소멸되기 때문에 학습되는 양이 0에 가까워져 학습이 더디게 진행되다가 오차를 더 줄이지 못하고 그 상태로 수렴하는 현상


해결 방법 : 렐루 활성화 함수의 사용



3. 성능이 나빠지는 문제 발생


경사 하강법 - 손실 함수의 비용이 최소가 되는 지점을 찾을 때까지 기울기가 낮은 쪽으로 계속 이동시키는 과정 반복

이 때 성능이 나빠지는 문제가 발생한다



해결 방법 : 확률적 경사 하강법, 미니 배치 경사 하강법 사용

경사 하강법의 유형



(1) 배치 경사 하강법 (Batch Gradient Descent, BGD)

전체 데이터셋에 대한 오류를 구한 후 기울기를 한 번만 계산하여 모델의 파라미터를 업데이트 하는 방법

→ 전체 훈련 데이터셋에 대해 가중치를 편미분하는 방법

손실 함수의 값을 최소화하기 위해 기울기(∇) 이용

$$W = W - a \nabla J(W, b)$$

(a : 학습률, J : 손실 함수)

**한 스텝에 모든 훈련 데이터셋을 사용하므로 학습이 오래 걸리는 단점이 있다

→ 이를 개선한 방법이 확률적 경사 하강법이다


(2) 확률적 경사 하강법 (Stochastic Gradient Descent, SGD)

임의로 선택한 데이터에 대해 기울기를 계산하는 방법

적은 데이터를 사용하므로 빠른 계산이 가능


단점 : 파라미터 변경 폭이 불안정(오른쪽 이미지), 배치 경사 하강법보다 정확도가 낮을 수 있음

장점 : 속도가 빠르다




(3) 미니 배치 경사 하강법(mini - batch gradient descent)

- 전체 데이터셋을 미니 배치 여러 개로 나누고
- 미니 배치 한 개마다 기울기를 구한 후
- 그것의 평균 기울기를 이용해 모델을 업데이트해서 학습하는 방법



장점 : 전체 데이터를 계산하는 것보다 빠름, 확률적 경사 하강법보다 안정적 → 가장 많이 사용

아래 그림처럼 파라미터 변경 폭이 확률적 경사 하강법보다 안정적이면서 속도도 빠름



[4.3 딥러닝 알고리즘]


딥러닝 알고리즘은 심층 신경망을 사용한다는 공통점이 있다

목적에 따라 CNN, RNN, RBM, DBN으로 나뉜다

[4.3.1 심층 신경망(DNN)]


: 입력층과 출력층 사이에 다수의 은닉층을 포함하는 인공 신경망을 의미한다

- 장점 : 다수의 은닉층을 두어 다양한 비선형적 관계를 학습할 수 있다
- 단점 : 학습 연산량이 많고 기울기 소멸 문제가 발생할 수 있다
- 해결 방법 : 드롭아웃, 렐루 함수, 배치 정규화 등의 적용



[4.3.2 합성곱 신경망(CNN)]

: 합성곱층과 풀링층을 포함하는 이미지 처리 성능이 좋은 인공 신경망 알고리즘을 의미한다
영상, 사진이 포함된 이미지 데이터에서 객체를 탐색하거나 객체 위치를 찾아내는 데 유용한 신경망



이미지에서 객체, 얼굴, 장면을 인식하기 위해 패턴을 찾는 데 특히 유용하다

- 예시

대표적인 합성곱 신경망 : LeNet-5, AlexNet


층을 더 깊게 쌓은 신경망 : VGG, GoogLeNet, ResNet

- 기존 신경망과의 차별성
 - 각 층의 입출력을 항상 유지
 - 이미지 공간 정보를 유지하면서 인접 이미지와 차이가 있는 특징을 효과적으로 인식
 - 복수 필터로 이미지의 특징을 추출하고 학습
 - 추출한 이미지의 특징을 모으고 강화하는 풀링층이 존재
 - 필터를 공유 파라미터로 사용하기 때문에 일반 인공 신경망과 비교하여 학습 파라미터가 매우 적음

[4.3.3 순환 신경망(RNN)]

: 시계열 데이터(음악, 영상 등) 같은 **시간 흐름에 따라 변화하는 데이터를 학습하기 위한 인공 신경망**

순환(recurrent) : 자기 자신을 참조한다, **현재 결과가 이전 결과와 연관**이 있다는 의미




- 순환 신경망의 특징
 - 시간성(temporal property)을 가진 데이터가 많다
 - 시간성 정보를 이용해 데이터 특징을 잘 다룬다
 - 시간에 따라 내용이 변하므로 데이터는 동적이고 길이가 가변적이다
 - 매우 긴 데이터를 처리하는 연구가 활발히 진행된다

- RNN은 기울기 소멸 문제로 인해 학습이 제대로 되지 않는 문제가 있다
→ 해결하고자 메모리 개념을 도입한 **LSTM(Long-Short Term Memory)**이 순환 신경망에서 많이 사용된다
- 자연어 처리 분야와 궁합이 맞는다
ex) 언어 모델링, 텍스트 생성, 자동 번역, 음성 인식, 이미지 캡션 생성 등

[4.3.4 제한된 볼츠만 머신]

볼츠만 머신(Boltzmann machine)은 가시층과 은닉층으로 구성된 모델이다

가시층은 은닉층과만 연결되는데, 이것이 **제한된 볼츠만 머신(Restricted Boltzmann machine, RBM)**이다



- RBM 특징
 - 차원 감소, 분류, 선형 회귀 분석, 협업 필터링, 특성 값 학습, 주제 모델링에 사용
 - 기울기 소멸 문제를 해결하기 위해 사전 학습 용도로 활용 가능
 - 심층 신뢰 신경망의 요소로 활용

[4.3.5 심층 신뢰 신경망]

심층 신뢰 신경망(Deep Velief Network, DBN):

입력층과 은닉층으로 구성된 **RBM**을 블록처럼 여러 층으로 쌓은 형태로 연결된 신경망이다

→ 사전 훈련된 **RBM**을 층층이 쌓아 올린 구조

**레이블이 없는 데이터에 대한 비지도 학습이 가능하다


**부분적인 이미지에서 전체를 연상하는 일반화, 추상화 과정을 구현할 때 사용하면 유용하다

- DBN의 학습 절차

(1) 가시층과 은닉층 1에 **RBM**을 사전 훈련한다

(2) 첫 번째 층 입력 데이터와 파라미터를 고정해 두 번째 층 **RBM**을 사전 훈련한다

(3) 원하는 층 개수만큼 **RBM**을 쌓아 올려 전체 DBN을 완성한다



- DBN의 특징

- 순차적으로 DBN을 학습시키며 계층 구조를 생성
- 비지도 학습으로 학습한다
- 위로 올라갈수록 추상적 특성을 추출한다
- 학습된 가중치를 다층 퍼셉트론의 가중치 초기값으로 사용