

4장. 딥러닝 시작


✓ 4.1 인공 신경망의 한계와 딥러닝 출현

퍼셉트론: 선형 분류기, 오늘날 인공 신경망에서 이용하는 구조

- 다수의 신호를 입력으로 받아 하나의 신호를 출력


AND 게이트: 모든 입력이 '1'일 때 작동

- 입력 중 하나라도 '0'을 갖는다면 작동을 멈춤




OR 게이트: 입력에서 둘 중 하나만 '1'이거나 둘 다 '1'일 때 작동

- 입력 모두가 '0'을 갖는 경우를 제외하고 작동



XOR 게이트: 배타적 논리합, 두 개 중 한 개만 '1'일 때 작동


- 단층 퍼셉트론에서는 학습이 불가능



다층 퍼셉트론: XOR 게이트의 문제를 극복하기 위함, 입력층과 출력층 사이에 하나 이상의 중간층 (은닉층)을 두어 비선형적으로 분리되는 데이터에 대해서도 학습이 가능하도록 함

딥러닝(심층 신경망): 입력층과 출력층 사이에 은닉층이 여러 개 있는 신경망


✓ 4.2 딥러닝 구조



딥러닝 구성 요소

- 층
 - 입력층: 데이터를 받아들이는 층
 - 은닉층: 모든 입력 노드부터 입력 값을 받아 가중합을 계산하고, 이 값을 활성화 함수에 적용하여 출력층에 전달하는 층
 - 출력층: 신경망의 최종 결과값이 포함된 층
- 가중치: 노드와 노드 간 연결 강도
- 바이어스: 가중합에 더해 주는 상수
- 가중합, 전달함수: 가중치와 신호의 곱을 합한 것
- 함수
 - 활성화 함수: 신호를 입력 받아 이를 적절히 처리하여 출력해 주는 함수

- 손실 함수: 가중치 학습을 위해 출력 함수의 결과와 실제 값 간의 오차를 측정하는 함수



가중치: 입력 값이 연산 결과에 미치는 영향력을 조절하는 요소


가중합(전달함수): 각 노드에서 들어오는 신호에 가중치를 곱한 값을 모두 더한 것

- 노드의 가중합이 계산되면 그것을 활성화 함수로 보내기 때문에 전달함수라고도 함


활성화 함수: 전달 함수에서 전달 받은 값을 출력할 때 일정 기준에 따라 출력 값을 변화시키는 비선형 함수

- 시그모이드 함수: 선형 함수의 결과를 0~1 사이에서 비선형 형태로 변형
 - 기울기 소멸 문제 때문에 딥러닝 모델에서는 잘 사용하지 않음


$$f(x) = \frac{1}{1 + e^{-x}}$$




- 하이퍼볼릭 탄젠트 함수: 선형 함수의 결과를 -1~1 사이에서 비선형 형태로 변형
 - 시그모이드에서 결과값의 평균이 0이 아닌 양수로 편향된 문제를 해결하는 데 사용했으나 기울기 소멸 문제는 여전히 발생



- 렐루 함수: 입력(x)이 음수일 때는 0을 출력하고, 양수일 때는 x 를 출력
 - 경사 하강법에 영향을 주지 않아 학습 속도가 빠르고 기울기 소멸 문제가 발생하지 않음
 - 일반적으로 은닉층에서 사용
 - 음수 값을 입력 받으면 항상 0을 출력하기 때문에 학습 능력 감소
 - 이를 해결하기 위해 리키 렐루 사용



- 리키 렐루 함수: 입력 값이 음수이면 0이 아닌 매우 작은 수를 반환
 - 입력 값이 수렴하는 구간 제거, 렐루 함수의 문제를 해결



- 소프트맥스 함수: 입력 값을 0~1 사이에 출력되도록 정규화하여 출력 값들의 총합이 항상 1이 되도록 함
 - 출력 노드의 활성화 함수로 많이 사용
 - 분자는 입력 신호 a_k 의 지수 함수, 분모는 모든 입력 신호의 지수 함수 합

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$$

손실 함수: 학습을 통해 얻은 데이터의 추정치가 실제 데이터와 얼마나 차이가 나는지 평가하는 지표

- 참고) 경사 하강법: 학습률과 손실 함수의 순간 기울기를 이용하여 가중치를 업데이트 하는 방법
 - 미분의 기울기를 이용하여 오차를 비교/최소화, 오차를 구하는 방법이 손실 함수
- 값이 클수록 많이 틀렸다는 의미
- 평균 제곱 오차(MSE): 실제 값과 예측 값의 차이를 제곱하여 평균을 낸 것
 - 회귀에서 손실 함수로 주로 사용

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

- 크로스 엔트로피 오차(CEE): 분류 문제에서 원-핫 인코딩을 했을 때만 사용
 - 경사 하강법 과정에서 학습이 지역 최소점에서 멈출 수 있기 때문에 자연 상수 e에 반대되는 자연 로그를 모델의 출력 값에 취함

$$CrossEntropy = - \sum_{i=1}^n y_i \log \hat{y}_i$$

$$\left(\begin{array}{l} \hat{y}_i: \text{신경망의 출력(신경망이 추정한 값)} \\ y_i: \text{정답 레이블} \\ i: \text{데이터의 차원 개수} \end{array} \right)$$

딥러닝 학습: 크게 순전파와 역전파 두 단계로 진행



순전파: 네트워크에 훈련 데이터가 들어올 때 발생, 데이터를 기반으로 예측 값을 계산하기 위해 전체 신경망을 교차

- 모든 뉴런이 이전 층의 뉴런에서 수신한 정보에 변환을 적용하여 다음 층의 뉴런으로 전공하는 방식

역전파: 손실(오차)이 계산되면 그 정보는 역으로 전파(출력층 -> 은닉층 -> 입력층)

- 출력층에서 시작된 손실 비용은 은닉층의 모든 뉴런으로 전파됨
- 은닉층의 뉴런은 각 뉴런이 원래 출력에 기여한 상대적 기여도에 따라 값이 달라짐

딥러닝의 문제점

- 은닉층이 많을수록 발생하는 문제
 - 과적합 문제: 훈련 데이터를 과하게 학습해서 발생
 - 훈련 데이터의 오차는 감소하지만, 검증 데이터는 오차가 증가할 수 있음
 - 해결: 드롭아웃 - 학습 과정 중 임의로 일부 노드들을 학습에서 제외
 - 기울기 소멸 문제: 출력층에서 은닉층으로 전달되는 오차가 크게 줄어들어 학습이 되지 않는 현상
 - 해결: 시그모이드나 하이퍼볼릭 탄젠트 대신 렐루 활성화 함수 사용
 - 성능이 나빠지는 문제: 경사 하강법을 반복하면서 성능이 나빠짐
 - 해결: 확률적 경사 하강법, 미니 배치 경사 하강법

경사 하강법

- 배치 경사 하강법: 전체 데이터셋에 대한 오류를 구한 후 기울기를 한 번만 계산하여 모델의 파라미터를 업데이트

- 전체 훈련 데이터셋에 대해 가중치를 편미분


손실 함수의 값을 최소화하기 위해 기울기(∇) 이용

$$W = W - a \nabla J(W, b)$$


(a : 학습률, J : 손실 함수)

- 확률적 경사 하강법: 임의로 선택한 데이터에 대해 기울기를 계산하는 방법

- 배치 경사 하강법의 학습이 오래 걸리는 단점을 개선




배치 경사 하강법




확률적 경사 하강법

- 미니 배치 경사 하강법: 전체 데이터셋을 미니 배치 여러 개로 나누고, 미니 배치 한 개마다 기울기를 구한 후 그것의 평균 기울기를 이용하여 모델을 업데이트해서 학습



확률적 경사 하강법



미니 배치 경사 하강법

+ 옵티마이저: 확률적 경사 하강법의 파라미터 변경 폭이 불안정한 문제를 해결하기 위함

- 속도 조정
 - 아다그라드: 변수의 업데이트 횟수에 따라 학습률을 조정
 - 많이 변화하지 않는 변수들의 학습률은 크게 하고, 많이 변화하는 변수들의 학습률은 작게 함
 - 아다델타: 아다그라드에서 G 값이 커짐에 따라 학습이 멈추는 문제를 해결하기 위함
 - 알엠에스프롬: 아다그라드의 $G(i)$ 값이 무한히 커지는 것을 방지하고자 제안
- 운동량 조정

- 모멘텀: 가중치를 수정하기 전에 이전 수정 방향을 참고하여 같은 방향으로 일정한 비율만 수정하는 방법
 - 확률적 경사 하강법과 함께 사용
- 네스테로프 모멘텀: 모멘텀 값이 적용된 지점에서 기울기 값을 계산
- 속도와 운동량에 대한 혼용 방법
 - 아담: 모멘텀과 알엠에스프롭의 장점을 결합

딥러닝의 이점

- 특성 추출: 데이터 별로 어떤 특징을 가지고 있는 찾아내고, 그것을 토대로 데이터를 벡터로 변환하는 작업
- 빅데이터의 효율적 활용: 딥러닝 학습을 이용한 특성 추출은 데이터 사례가 많을수록 성능 향상

✓ 4.3 딥러닝 알고리즘

심층 신경망(DNN): 입력층과 출력층 사이에 다수의 은닉층을 포함하는 인공 신경망

- 다수의 은닉층을 두어 다양한 비선형적 관계 학습 가능, 그러나 학습을 위한 연산량이 많고 기울기 소멸 문제 등 발생
 - 해결: 드롭아웃, 렐루 함수, 배치 정규화 등을 적용

합성곱 신경망(CNN): 합성곱층과 풀링층을 포함하는 이미지 처리 성능이 좋은 인공 신경망 알고리즘

- 대표적으로 LeNet-5, AlexNet
- 기존 신경망과의 차별점:
 - 각 층의 입출력 형상을 유지
 - 이미지의 공간 정보를 유지하면서 인접 이미지와 차이가 있는 특징을 효과적으로 인식
 - 복수 필터로 이미지의 특징을 추출하고 학습
 - 추출한 이미지의 특징을 모으고 강화하는 풀링층이 있음
 - 필터를 공유 파라미터로 사용하기 때문에 일반 인공 신경망과 비교하여 학습 파라미터가 매우 적음

순환 신경망(RNN): 시계열 데이터 같은 시간 흐름에 따라 변화하는 데이터를 학습하기 위한 인공 신경망

- 순환 신경망의 특징:
 - 시간성을 가진 데이터가 많음
 - 시간성 정보를 이용하여 데이터의 특징을 잘 다룸

- 시간에 따라 내용이 변하므로 데이터는 동적이고, 길이가 가변적
- 매우 긴 데이터를 처리하는 연구가 활발히 진행
- 기울기 소멸 문제 발생, LSTM이 순환 신경망에 많이 사용

제한된 볼츠만 머신: 가시층과 은닉층으로 구성된 모델 중 가시층이 은닉층과만 연결된 것

- 제한된 볼츠만 머신의 특징:
 - 차원 감소, 분류, 선형 회귀 분석, 협업 필터링, 특성 값 학습, 주제 모델링에 활용
 - 기울기 소멸 문제를 해결하기 위해 사전 학습 용도로 활용 가능
 - 심층 신뢰 신경망의 요소로 활용

심층 신뢰 신경망(DBN): 입력층과 은닉층으로 구성된 제한된 볼츠만 머신을 블록처럼 여러 층으로 쌓은 형태로 연결된 신경망

- 학습 절차:
 1. 가시층과 은닉층 1에 제한된 볼츠만 머신을 사전 훈련
 2. 첫 번째 층 입력 데이터와 파라미터를 고정하여 두 번째 층 제한된 볼츠만 머신을 사전 훈련
 3. 원하는 층 개수만큼 제한된 볼츠만 머신을 쌓아 올려 전체 DBN 완성
- 심층 신뢰 신경망의 특징:
 - 순차적으로 심층 신뢰 신경망을 학습시켜 가면서 계층적 구조 생성
 - 비지도 학습으로 학습
 - 위로 올라갈수록 추상적 특성을 추출
 - 학습된 가중치를 다층 퍼셉트론의 가중치 초기 값으로 사용

✓ 4.4 우리는 무엇을 배워야 할까?

머신 러닝을 학습할지, 딥러닝을 학습할지는 주어진 데이터를 활용하여 어떤 결과를 얻고 싶은지에 따라 다름

- 복잡한 비선형 데이터에 대한 분류/예측을 하고 싶다면 딥러닝으로 학습