


5.3. 전이학습

✓ 전이 학습(transfer learning)

정의

- 이미지넷(ImageNet)처럼 아주 큰 데이터셋을 써서 훈련된 모델의 가중치를 가져와 해결하려는 과제에 맞게 보정해서 사용하는 것
- 사전 훈련된 모델(네트워크): 아주 큰 데이터셋을 사용하여 훈련된 모델

⇒ 비교적 적은 수의 데이터를 가지고도 원하는 과제를 해결할 수 있음



전이 학습을 위한 방법

1. 특성 추출 기법
2. 미세 조정 기법


✓ 특성 추출 기법

정의

- ImageNet 데이터셋으로 사전 훈련된 모델을 가져온 후 마지막에 완전연결층 부분만 새로 만듦
- 학습할 때는 마지막 완전연결층(이미지의 카테고리를 결정하는 부분)만 학습하고 나머지 계층들을 학습되지 않도록 함

구조

- 이미지 분류를 위해 두 부분으로 구성
 1. **합성곱층**: 합성곱층과 풀링층으로 구성
 2. **데이터 분류기(완전연결층)**: 추출된 특성을 입력받아 최종적으로 이미지에 대한 클래스를 분류하는 부분
- 사전 훈련된 네트워크의 합성곱층(가중치 고정)에 새로운 데이터를 통과시키고, 그 출력을 데이터 분류기에서 훈련시킴
- 사용 가능한 이미지 분류 모델
 - Xception
 - Inception V3
 - ResNet50
 - VGG16
 - VGG19
 - MobileNet




예시

Week4_예습과제_방민지.ipynb 참고

✓ 미세 조정 기법

정의

- 특성 추출 기법에서 더 나아가 사전 훈련된 모델과 합성곱층, 데이터 분류기의 가중치를 업데이트하여 훈련시키는 방식
- 특성 추출: 목표 특성을 잘 추출했다는 전제하에 좋은 성능을 낼 수 있음
⇒ 특성이 잘못 추출되었다면 미세 조정 기법으로 새로운 이미지 데이터를 사용하여 네트워크의 가중치를 업데이트해서 특성을 다시 추출
- 사전 학습된 모델을 목적에 맞게 재학습시키거나 학습된 가중치의 일부를 재학습시키는 것



특징

- 사전 훈련된 네트워크를 미세 조정하여 분석하려는 데이터셋이 잘 맞도록 모델의 파라미터를 조정하는 기법
- ⇒ 미세 조정 과정에서 많은 연산량 필요
- ⇒ GPU 사용 권장

훈련시키려는 데이터셋의 크기, 사전 훈련된 모델에 따른 전략

1. 데이터셋이 크고 사전 훈련된 모델과 유사성이 작을 경우

- 모델 전체를 재학습

- 데이터셋 크기가 크기 때문에 재학습 시키는 것이 좋은 전략

2. 데이터셋이 크고 사전 훈련된 모델과 유사성이 클 경우

- 합성곱층의 뒷부분(완전연결층과 가까운 부분)과 데이터 분류기를 학습
- 데이터셋이 유사
 - ⇒ 전체를 학습시키는 것보다는 강한 특징이 나타나는 합성곱층의 뒷부분과 데이터 분류기만 새로 학습해도 최적의 성능을 낼 수 있음

3. 데이터셋이 작고 사전 훈련된 모델과 유사성이 작을 경우

- 합성곱층의 일부분, 데이터 분류기를 학습
- 데이터가 적음
 - ⇒ 일부 계층에 미세 조정 기법을 적용한다고 해도 효과가 없을 수 있음
 - ⇒ 합성곱층 중 어디까지 새로 학습시켜야 할지 적당히 설정해야함

4. 데이터셋이 작고 사전 훈련된 모델과 유사성이 클 경우

- 데이터 분류기만 학습
 - 데이터가 적음
 - ⇒ 많은 계층에 미세 조정 기법을 적용하면 과적합이 발생할 수 있음
 - ⇒ 최종 데이터 분류기(완전연결층)에 대해서만 미세 조정 기법 적용
- ⇒ 미세 조정은 파라미터 업데이트 과정에서 파라미터에 큰 변화를 주게 되면 과적합 문제가 발생할 수 있음
- ⇒ 정교하고 미세한 파라미터 업데이트 필요

5.4. 설명 가능한 CNN

✓ 설명 가능한 CNN(explainable CNN)

정의

- 딥러닝 처리 결과를 사람이 이해할 수 있는 방식으로 제시하는 기술
- 기존 CNN: 내부 동작을 설명하기 어려워 결과를 신뢰하기 어려움
⇒ CNN 처리 과정을 시각화
- CNN을 구성하는 각 중간 계층부터 최종 분류까지 입력된 이미지에서 특성이 어떻게 추출되고 학습되는지를 시각적으로 설명할 수 있어야 결과에 대한 신뢰성을 얻을 수 있음

CNN의 시각화 방법

1. 필터에 대한 시각화
2. 특성 맵에 대한 시각화

✓ 특성 맵/활성화 맵 시각화

정의

- 입력 이미지 또는 다른 특성 맵처럼 필터를 입력에 적용한 결과
- 특정 맵에서 입력 특성을 감지하는 방법을 이해할 수 있도록 돕는 것

예제

Week4_예습과제_방민지.ipynb 참고


5.5. 그래프 합성곱 네트워크

✓ 그래프

정의

- 방향성이 있거나(directed) 없는(undirected) 엣지(edge)로 연결된 노드(nodes=verticals)의 집합
- 노드, 엣지: 풀고자 하는 문제에 대한 전문가의 지식/직관 등으로 구성

구성 요소




- 노드
: 그림에서의 파란 원, 원소
- 엣지
: 두 노드를 연결한 선, 결합 방법(single, double, triple, aromatic 등)

✓ 그래프 신경망(Grapg Neural Network, GNN)

정의

- 그래프 구조에서 사용하는 신경망

그래프 데이터에 대한 표현



1단계. 인접 행렬(adjacency matrix)

- 그림의 왼쪽 같은 네트워크가 있을 때 노드 n 개를 $n \times n$ 행렬로 표현
- 생성된 인접 행렬 내의 값은 ' A_{ij} 는 i 와 j 의 관련성 여부'를 만족하는 값으로 채움

⇒ 컴퓨터가 이해하기 쉽게 그래프로 표현하는 과정

2단계. 특성 행렬(feature matrix)

- 인접 행렬만으로는 특성을 파악하기 어렵기 때문에 단위 행렬 적용
- 각 입력 데이터에서 이용할 특성 선택
- 특성 행렬에서 각 행은 선택된 특성에 대해 각 노드가 갖는 값을 의미
 - 예) 첫 번째 행은 첫 번째 노드의 특성 값

⇒ 각 노드에 대한 특성을 한눈에 파악하기 쉽게 표현


⇒ 특성 행렬 과정을 거쳐 그래프 특성이 추출

✓ 그래프 합성곱 네트워크(Graph Convolutional Network, GCN)

정의

- 이미지에 대한 합성곱을 그래프 데이터로 확장한 알고리즘

구조



1. 리드아웃

- 특성 행렬을 하나의 벡터로 변환하는 함수
- 전체 노드의 특성 벡터에 대해 평균을 구하고 그래프 전체를 표현하는 하나의 벡터를 생성

2. 그래프 합성곱층

- GCN에서 가장 중요한 부분
- 그래프 합성곱층을 이용한 그래프 형태의 데이터는 행렬 형태의 데이터로 변환되어 딥러닝 알고리즘을 적용할 수 있음
(기존 그래프 형태의 데이터로는 딥러닝 알고리즘을 적용할 수 없음)

활용

- SNS에서 관계 네트워크
- 학술 연구에서 인용 네트워크
- 3D Mesh