

4주차 스터디

교재 : 딥러닝 파이토치 교과서

분량 : 5.1장 ~ 5.2장

과제 기간 : ~2025-03-31


5.3 전이 학습

일반적으로 CNN 기반의 딥러닝 모델을 제대로 훈련시키려면 많은 양의 데이터가 필요하다
그러나 큰 데이터셋을 확보하기에는 많은 돈과 시간이 필요하다

→ 현실적인 어려움을 해결한 것이 **전이 학습(transfer learning)**

전이 학습(transfer learning) :

- 이미지넷(ImageNet)처럼 **아주 큰 데이터셋을 써서 훈련된 모델의 가중치**를 가져와 우리가 해결하려는 **과제에 맞게 조정해서 사용하는 것**을 의미한다
- 아주 큰 데이터셋을 사용해 훈련된 모델을 **사전 훈련된 모델(네트워크)**라고 한다
- 결과적으로는 **비교적 작은 수의 데이터**를 갖고도 우리가 원하는 **과제를 해결할 수 있다**




전이 학습을 위한 방법으로는 **특성 추출 기법**과 **미세 조정 기법**이 있다

5.3.1 특성 추출 기법

특성 추출(feature extractor) :

- ImageNet 데이터셋으로 사전 훈련된 모델을 가져온 뒤, **마지막에 완전연결층 부분만 새로 만든다**

- 학습할 때는 **마지막 완전연결층만 학습**하고 나머지 계층들은 학습되지 않도록 한다
- 특성 추출은 이미지 분류를 위해 두 부분으로 구성된다
 1. 합성곱층 : 합성곱층과 풀링층으로 구성
 2. 데이터 분류기(완전연결층) : 추출된 특성을 입력받아 최종적으로 이미지에 대한 클래스를 분류하는 부분
- 사전 훈련된 네트워크의 합성곱층(가중치 고정)에 새로운 데이터를 통과시키고 그 출력을 데이터 분류기에서 훈련시킨다
- 사용 가능한 이미지 분류 모델은 아래와 같다
: Xception, Inception V3, ResNet50, VGG16, VGG19, MobileNet



5.3.2 미세 조정 기법


미세 조정(fine tuning) :

- 특성 추출 기법에서 더 나아가 사전 훈련된 모델과 합성곱층, 데이터 분류기의 **가중치를 업데이트하여 훈련시키는 방법**
- 특성 추출은 목표 특성을 잘 추출했다는 전제하에 좋은 성능이다

⇒ 특성이 잘못 추출되었다면 미세조정 기법으로 새로운 이미지 데이터를 사용해 네트워크 가중치를 업데이트해서 특성을 다시 추출할 수 있다

- 즉, 사전 학습된 모델을 목적에 맞게 재학습시키거나 학습된 가중치 일부를 재학습시키는 것
- 미세 조정 기법은 **사전 훈련된 네트워크를 미세 조정하여 분석하려는 데이터셋에 잘 맞도록 모델의 파라미터를 조정하는 기법**
- 미세 조정 과정에서 많은 연산량이 필요하므로 GPU 사용을 권장한다
- 미세 조정 기법은 훈련시키려는 데이터셋의 크기와 사전 훈련된 모델에 따라 다른 전략을 세울 수 있다

	데이터셋이 클 때	데이터셋이 작을 때
훈련된 모델과 유사성이 클 때	합성곱층의 뒷부분(=완전연결층과 가까운 부분)과 데이터 분류기를 학습시킨다 * 합성곱층의 뒷부분과 데이터 분류기만 새로 학습하더라도 최적의 성능을 낼 수 있다	데이터 분류기만 학습시킨다 * 데이터가 적기 때문에 많은 계층에 미세 조정 기법을 적용하면 과적합이 발생할 수 있다 * 최종 데이터 분류기인 완전 연결층에만 미세 조정 기법을 적용한다
훈련된 모델과 유사성이 작을 때	모델 전체를 재학습 시킨다 * 데이터셋 크기가 커서 재학습 시키는 것이 좋은 전략이다	합성곱층의 일부분과 데이터 분류기를 학습시킨다 * 데이터가 적기 때문에 일부 계층에 미세 조정 기법을 적용해도 효과가 없을 수 있음



5.4 설명 가능한 CNN

설명 가능한 CNN :

- 딥러닝 처리 결과를 **사람이 이해할 수 있는 방식으로 제시하는 기술**
- CNN은 블랙박스과 같아 내부에서 어떻게 동작하는지 설명하기 어렵다
 - CNN으로 얻은 결과는 신뢰하기 어렵다
 - 이를 해결하기 위해서는 **CNN 처리 과정을 시각화** 할 필요가 있다
 - CNN을 구성하는 각 중간 계층부터 최종 분류까지, 입력된 이미지에서 특성이 어떻게 추출되고 학습하는지를 시각적으로 설명할 수 있어야 결과에 대한 신뢰성을 얻을 수 있다
- CNN의 시각화 방법 : 필터에 대한 시각화, 특성 맵에 대한 시각화

5.4.1 특성 맵 시각화

특성 맵(feature map, 혹은 활성화 맵) :

- 입력 이미지 또는 다른 특성 맵처럼 필터를 입력에 적용한 결과
- "특정 입력 이미지에 대한 특성 맵을 시각화한다"는 의미는 특성 맵에서 입력 특성을 감지하는 방법을 이해할 수 있도록 돕는 것이다

+) 필터에 대한 시각화에 대한 설명

https://velog.io/@tobigs_xai/2-CNN-Filter-Visualization


5.5 그래프 합성곱 네트워크

그래프 합성곱 네트워크(graph convolutional network) : 그래프 데이터를 위한 신경망

5.5.1 그래프란

그래프 :

- 방향성이 있거나 없는 엣지로 연결된 노드의 집합
- 노드, 엣지 : 일반적으로 풀고자 하는 문제에 대한 전문적 지식이나 직관 등으로 구성된다



- 노드는 원소들을 의미하고 엣지는 결합 방법(single, double, triple, aromatic 등)을 의미한다

5.5.2 그래프 신경망

그래프 신경망(Graph Neural Network, GNN) :

- 그래프 구조에서 사용하는 신경망
- 그래프 데이터에 대한 표현은 다음 두 단계로 이뤄진다


1단계. 인접 행렬(adjacency matrix)

- 네트워크가 있을 때, 노드 n 개를 $n \times n$ 행렬로 표현한다
- 생성된 인접 행렬 내의 값은 A_{ij} 는 i 와 j 의 관련성 여부를 만족하는 값으로 채운다
- 즉, 인접 행렬 과정은 컴퓨터가 이해하기 쉽게 그래프로 표현하는 과정이다

2단계. 특성 행렬(feature matrix)

- 인접 행렬만으로는 특성을 파악하기 어렵기 때문에 단위 행렬을 적용한다
- 각 입력 데이터에서 이용할 특성을 선택한다


- 특성 행렬에서 각 행은 선택된 특성에 대해 각 노드가 갖는 값을 의미한다
ex) 첫 번째 행은 첫 번째 노드의 특성 값
- 이제 노드 1,2,3,4에 대한 특성을 한 눈에 파악하기 쉽게 표현되었다
- 즉, 특성 행렬 과정을 거쳐 그래프 특성이 추출된다



5.5.3 그래프 합성곱 네트워크

그래프 합성곱 네트워크(Graph Convolution Network, GCN) :

- 이미지에 대한 합성곱을 그래프 데이터로 확장한 알고리즘이다
- 구조는 아래 이미지와 같다 :



- 리드아웃(readout) : 특성 행렬을 하나의 벡터로 변환하는 함수
→ 즉 전체 노드의 특성 벡터에 대해 평균을 구하고 그래프 전체를 표현하는 하나의 벡터를 생성한다

- GCN에서 가장 중요한 부분은 그래프 합성곱층이다
 - 그래프 합성곱층을 이용한 그래프 형태의 데이터는 행렬 형태의 데이터로 변환되어 딥러닝 알고리즘을 적용할 수 있기 때문이다
 - 기존 그래프 형태의 데이터로는 딥러닝 알고리즘을 적용할 수 없다
- GCN 활용 분야 : SNS 관계 네트워크, 학술 연구 인용 네트워크, 3D Mesh