

✓ 10장. 비전 트랜스포머

ViT(Vision Transformer): 이미지 인식을 위한 딥러닝 모델

- CNN 모델의 합성곱 계층 방법 사용 X, 트랜스포머 모델에서 사용되는 셀프 어텐션을 적용
- 전체 이미지를 한 번에 처리하는 방식으로 구현
- 스윈 트랜스포머/CvT: 2차원 구조의 이미지 특성을 온전히 반영하지 못하는 문제 해결
 - 스윈 트랜스포머: 로컬 윈도우를 활용해 각 계층의 어텐션이 되는 패치의 크기와 개수를 다양하게 구성해 이미지의 특징을 학습
 - CvT: 기존 합성곱 연산 과정을 ViT에 적용한 모델, 저수준 특징과 고수준 특징을 계층적으로 반영
 - 어텐션 연산 과정에서 쿼리, 키, 값 중 키와 값을 축소해 계산 복잡도를 감소

✓ ViT

ViT vs BERT

- BERT: 문장보다 작은 단위의 토큰들이 순차적으로 입력
- ViT 모델: 이미지가 격자로 작은 단위의 이미지 패치로 나뉘어 순차적으로 입력
 - ViT 모델에 사용되는 입력 이미지 패치는 왼쪽 -> 오른쪽, 위->아래로 표현된 시퀀셜 배열을 가정

합성곱 모델 vs ViT 모델

- 합성곱 신경망의 임베딩: 이미지 패치 중 일부만 선택하여 학습, 이를 통해 이미지 전체의 특징을 추출
 - 이미지 정보를 표현하는 데 수많은 계층 필요
 - 이미지의 공간적 위치 고려
- ViT 임베딩: 이미지를 작은 패치들로 나눠 각 패치 간의 상관관계를 학습
 - 모든 이미지 패치가 학습에 관여, 높은 수준의 이미지 표현 제공
 - 트랜스포머 모델은 어텐션 거리를 계산하여 오직 한 개의 ViT 레이어로 전체 이미지 정보를 쉽게 표현
 - 더 작은 모델로도 높은 성능 얻기 가능
 - 입력 이미지의 크기가 고정, 크기가 다른 이미지를 처리하려면 이미지 크기를 맞추는 전처리 필요
 - 패치 간의 상대적 위치만 고려, 이미지 변환에 취약할 수 있음

ViT의 귀납적 편향

- 귀납적 편향: 일반화 성능 향상을 위한 모델의 가정
- ViT 모델은 입력 데이터의 다양한 쿼리, 키, 값의 임베딩 형태로 일반화된 관계를 학습
 - 귀납적 편향이 거의 없고, 대용량 데이터에 대해서 이미지 특징들의 관계를 잘 학습

표 10.1 딥러닝 모델의 귀납적 편향

딥러닝 모델	귀납적 편향
합성곱 신경망(CNN)	지역적 편향
순환 신경망(RNN)	순차적 편향
ViT	귀납적 편향이 거의 없음

ViT 모델

- 패치 임베딩과 인코더 계층으로 구성
 - 패치 임베딩: 입력 이미지를 트랜스포머 구조에 맞게 일정한 크기의 패치로 나뉜 뒤 각 패치를 벡터 형태로 변환
 - 인코더: 각 패치와의 관계를 학습




그림 10.4 ViT 모델 구조

패치 임베딩: 입력 이미지를 작은 패치로 분할하는 과정

- 이미지 크기를 맞추는 전처리 수행

- 전체 이미지를 패치 크기로 분할해 시퀀셜 배열을 만들 (합성곱 신경망의 계층 활용)
- 커널 크기(kernel size)와 간격(stride)을 설정, 하이퍼 파라미터로 정의
 - $\text{patch size} = (\text{image size} - \text{kernel size}) / \text{stride}$
- 분할된 이미지 패치들을 배열 형태로 나열할 때 왼쪽에서 오른쪽, 위에서 아래 순서로 배열
 - 가장 왼쪽에 분류 토큰 추가
 - 전체 이미지를 대표하는 벡터로 특정 문제를 예측
- 위치 임베딩을 사용하여 인접한 패치 간의 관계를 학습
 - 위치 정보를 임베딩 벡터로 변환하고 기존 이미지 패치 벡터들과 더함
- 계층 정규화를 적용하면 패치 임베딩이 만들어짐

인코더 계층: 각 패치를 벡터로 변환한 것을 입력으로 받아 다양한 쿼리, 키, 값 임베딩의 관계를 학습

- 인코더 레이어를 반복적으로 적용한 후, 마지막 레이어에서 분류 토큰의 특징 벡터를 추출
 - 이미지 데이터를 잘 표현하는 특징 벡터
 - 다양한 이미지 분류 및 검색 문제를 해결하는 데 사용
 - 시퀀셜 산출물을 모두 사용하는 것 X, 전체 이미지의 특징을 잘 표현하는 분류 토큰 벡터만 사용

혼동 행렬을 통해 모델 개선, 정확도 향상 가능

- 하이퍼파라미터 조정, 모델 구조 변경, 전처리 과정 개선, 데이터 증강 등

✓ Swin Transformer

스윈 트랜스포머: 대규모 비전 인식 모델

- 계층적 특징 맵을 구성해 1차 계산 복잡도를 가짐
- 이미지 분류, 객체 감지, 영상 분할과 같은 인식 작업에서 강력한 성능, 트랜스포머 구조보다 이미지 특성을 더 잘 표현
- 시프트 윈도 기술 활용: 입력 이미지를 일정한 크기의 패치로 분할, 이 패치들을 쌓아 윈도 구성
 - 구성된 윈도 영역만 셀프 어텐션 계산
 - 계층마다 어텐션이 수행되는 패치의 크기와 개수를 계층적으로 적용, 높은 해상도와 다양한 크기를 가진 객체를 효율적으로 처리

ViT vs 스윈 트랜스포머

- ViT 모델

- 다양한 이미지 크기와 종횡비를 가진 데이터 세트에 대해서는 적용이 어려움
- 패치 단위로 입력을 받기 때문에 이미지의 공간 정보가 완전히 보존되지 않을 수 있음
- 대규모 데이터세트에서는 학습에 필요한 컴퓨팅 자원을 많이 사용
- 스윈 트랜스포머
 - 로컬 윈도우 활용, 물체의 크기나 해상도를 계층적으로 학습
 - 로컬 윈도우: 스윈 트랜스포머에서 입력 이미지를 처리하기 위해 사용되는 고정 크기의 작은 윈도우
 - ViT보다 더 높은 정확도, 더 적은 매개변수 수, 더 넓은 범위의 이미지 크기와 종횡비
 - 로컬 윈도우가 각 패치의 세부 정보에 집중, 시프트 윈도우를 통해 전역 특징 확인 가능

표 10.4 ViT와 스윈 트랜스포머 비교

	ViT	스윈 트랜스포머
분류 헤드	[CLS] 토큰 사용	각 토큰의 평균값 사용
로컬 윈도우 사용	X	O
상대적 위치 편향 사용	X	O
계층별 패치 크기	동일함	다양함

스윈 트랜스포머 모델 구조

- 이미지를 패치 파티션으로 구분, 선형 임베딩/스윈 트랜스포머 블록/ 패치 병합 연산이 반복적으로 수행
 1. 입력 이미지를 일정한 크기의 패치로 분할, 각 패치에 대해 선형 임베딩 수행
 - 각 패치는 고정된 차원의 벡터로 변환
 2. 분할된 패치들을 기반으로 스윈 트랜스포머 블록 구성, 어텐션 계층/계층 정규화/다층 퍼셉트론 등을 포함
 3. 패치를 병합에 전체 이미지에 대한 분류 수행




그림 10.7 스윈 트랜스포머 구조

- 패치 파티션: 입력 이미지를 작은 사각형 패치로 분할해 처리하는 방식
- 패치 병합: 인접한 패치들의 정보를 저차원으로 축소하는 과정
- 스윈 트랜스포머 블록은 계층 정규화, W-MSA, MLP, SW-MSA 등으로 구성
 - W-MSA: 로컬 윈도우를 사용하는 멀티 헤드 셀프 어텐션
 - 이미지에서 일정한 크기의 윈도우 영역 설정, 해당 영역 내 픽셀 간의 어텐션을 계산
 - 연산량은 대폭 감소, 그러나 윈도우 내부의 이미지 패치 영역에만 셀프 어텐션을 수행한다는 단점
 - S-MSA: 윈도우 사이의 연결성 구축, 윈도우 간의 관계성 정보 추출
 - 윈도우를 가로 또는 세로 방향으로 이동한 후, 인접한 윈도우 간의 셀프 어텐션을 계산
 - 순환 시프트와 어텐션 마스크를 사용
 - 순환 시프트: 로컬 윈도우가 이동할 때 이동한 위치의 정보를 이전 위치에서 가져오는 것
 - 어텐션 마스크: 이동된 위치에서 연산을 수행하지 않도록 방지
 - 역순환 시프트: 원래 로컬 윈도우 구조로 복원
- 셀프 어텐션은 상대적 위치 편향을 고려

수식 10.2 상대적 위치 편향을 고려한 셀프 어텐션


$$Attention(Q, K, V) = SoftMax(QK^T / \sqrt{d} + B)V$$

- Q, K, V는 쿼리, 키, 값 벡터를 의미, d는 임베딩 차원
- 스윈 트랜스포머는 크게 swin과 classifier로 구분
 - swin: 패치 파티션, 선형 임베딩과 함께 네 개의 스테이지가 수행
 - 스테이지 이후 계층 정규화와 풀링 통과
 - classifier: 클래스 구분
- [CLS] 토큰을 사용하지 않음, 토큰들의 평균값을 사용해 분류 진행
- SwinLayer: 기본적인 빌딩 블록이 되는 계층
- MLP 계층: 두 개의 연속된 선형 변환 계층과 GELU 활성화 함수로 구성
 - GELU: ReLU와 유사한 형태, 가우시안 분포에 대한 누적 분포 함수

✓ CvT

CvT: 합성곱 신경망 구조에서 활용하는 계층형 구조를 ViT에 적용한 모델

- 이미지의 지역 특징과 전역 특징을 모두 활용해 비교적 적은 수의 매개변수로 높은 성능을 보임
- 합성곱 계층의 지역 특징 추출, ViT의 셀프 어텐션 계층으로 전역 특징을 결합해 이미지를 처리



- CvT 모델의 계층적 특징 구조
 - 저수준 계층: 선 또는 점에 대한 특징을 표현
 - 중간 수준: 눈이나 귀와 같은 특징을 표현
 - 고수준: 얼굴 구조에 대한 특징을 표현
- 이미지를 처리하기 전에 합성곱 연산을 통해 특징 맵을 추출
- ViT 모델과 CvT 모델의 차이

표 10.4 ViT와 CvT 모델 비교

모델	위치 임베딩	패치 임베딩	어텐션 임베딩	계층형 구조
ViT	O	겹치지 않는 선형 임베딩	선형 임베딩	X
CvT	X	겹치는 합성곱 임베딩 (overlapping)	합성곱 임베딩	O

합성곱 토큰 임베딩: 2D로 재구성된 토큰 맵에서 중첩 합성곱 연산을 수행하는 임베딩

- CvT 모델은 이미지의 2D 구조를 보존하면서도 셀프 어텐션을 계산하는 방식을 사용
 - 이미지 패치를 2D 합성곱 임베딩을 사용해 쿼리, 키, 값 임베딩으로 변환

어텐션에 대한 합성곱 임베딩: 2D로 재구성된 토큰맵에서 분리 가능한 합성곱 연산을 적용해 성능 저하 및 계산 복잡도를 낮추는 연산

- CvT 모델은 매개변수의 수를 줄이기 위해 쿼리, 키, 값의 차원을 축소
- 어텐션 맵: 쿼리 패치 임베딩과 키 패치 임베딩에 대한 중요도
- CvT 모델은 트랜스포머 계층이 깊어질수록 패치 간의 관계를 학습하는 길이를 축소시키는 대신 벡터의 차원을 증가시켜 모델의 매개변수 수를 대폭 감소
- CvT 모델은 크게 세 개의 스테이지로 구성된 cvt와 계층 정규화, 분류기로 구성
 - 분류기 이전에 풀링 계층은 존재 X