

13주차 스터디


교재 : 자연어 처리와 컴퓨터비전

분량 : 7장 part 2

과제 기간 : ~2025-06-02

BERT

- Bidirectional Encoder Representations from Transformers
- 2018 구글에서 발표한 언어 모델, 트랜스포머 기반 양방향 인코더를 사용하는 자연어 처리 모델
- 양방향(Bidirectional) 인코더 :
 - 입력 시퀀스를 양쪽 방향에서 처리
 - 이전과 이후의 단어를 모두 참조하면서 단어의 의미와 문맥을 파악
 - 기존의 언어 모델은 문장을 좌>우로 순차적으로 학습해 단어의 의미와 문맥을 파악할 때 이전 단어만 고려했음
 - BERT는 양방향(이전과 이후 단어)으로 참조해 단어의 의미와 문맥을 파악함⇒ 기존 모델보다 더 정확한 문맥 파악, 다양한 자연어 처리 작업에서 높은 성능
- BERT 특징
 - 대규모 데이터를 이용해 사전에 학습되어 있으므로, 전이 학습에 주로 활용됨
 - 일부 또는 전체를 다른 작업에서 재사용해 적은 양의 데이터로도 높은 정확도를 달성할 수 있고 모델 학습 시간을 크게 단축할 수 있다
 - 트랜스포머 인코더 기반, 재활용을 통해 학습 데이터의 양과 다양성을 고려한 높은 성능을 보인다
- BERT에서 사용되는 트랜스포머 모듈



- BERT : 입력 문장의 의미와 구조를 학습하고 다양한 자연어 처리 작업에 적용할 수 있는 사전 학습된 언어 모델
- 트랜스포머의 인코더 모듈만을 사용해 입력 문장을 처리한다
- 인코더는 입력 문장의 단어들을 임베딩 > 각 단어의 의미를 벡터화한다 > 순차적으로 처리해 문장 전체의 의미를 추출한다
- 입력 문장의 단어를 좌우 양방향으로 처리해 문맥 정보를 모델링하므로 인코더 계층만을 사용해 학습한다
- BERT는 사전학습을 위해 마스킹된 언어 모델링(MLM)과 다음 문장 예측 방법(NSP)을 사용한다

사전 학습 방법

[마스킹된 언어 모델링, Masked Language Modeling, MLM]

- 입력 문장에서 임의로 일부 단어를 마스킹하고 해당 단어를 예측하는 방식
- ex) I'm learning PyTorch
 - learning 마스킹 : I'm [MASK] PyTorch 가 되어 BERT는 MASK에 들어갈 단어를 예측

- 이 과정에서 양방향 문맥 정보를 참고한다
- BERT는 입력 문장에서 누락된 단어를 추론하는 능력을 갖게 된다 → 이를 통해 문장 전체 의미를 이해하는 능력이 향상됨

[다음 문장 예측, Next Sentence Prediction, NSP]

- 두 개의 문장이 주어졌을 때 두 번째 문장이 첫 번째 문장의 다음에 오는 문장인지 여부를 판단하는 작업
- ex) I'm learning PyTorch , Pytorch is machine learning library
 - BERT는 이 두 문장이 연속적인 관계인지 아닌지 예측
 - 이 과정에서 BERT는 두 문장 간의 관계를 학습
 - 문장 간의 의미적인 유사성을 파악

[BERT 모델의 토큰]

- 입력 문장에 특수한 토큰들을 추가해 모델이 학습하고 추론하는 과정에서 필요한 정보를 제공한다

1. [CLS] 토큰

- 입력 문장의 시작 부분에 추가한다
- 문장 분류 작업을 위한 정보를 제공한다
- → 이를 통해 모델은 입력 문장이 어떤 유형의 문장인지 미리 파악할 수 있게 된다
- ex) 이전의 문장 분류 작업에서는 이 토큰이 입력 문장이 긍정적, 부정적인지 혹은 문장 내에서 어떤 객체가 언급되는지 등을 분류하는데 사용됨


2. [SEP] 토큰

- 입력 문장 내에서 두 개 이상의 문장을 구분하기 위해 사용
- 문장 분류 작업에서 두 개의 문장을 입력 받을 때, [SEP] 토큰을 사용해 두 문장을 구분
- → 이를 통해 모델은 입력 문장을 두 개의 독립적인 문장으로 인식
- 각각의 문장에 대한 정보를 정확하게 파악할 수 있게 된다

3. [MASK] 토큰

- 입력 문장 내에서 임의로 선택된 단어를 가리키는 특별한 토큰

- 주어진 문장에서 일부 단어를 가린 후 모델의 학습과 예측에 활용됨
- ex) 언어 모델링 작업에서 [MASK] 토큰은 마스킹된 실제 단어를 예측하는 데 사용
- ex) [CLS] 문장-1 [SEP] 문장 -2 [MASK][SEP]
- BERT 모델의 입력 임베딩 구조와 MLM, NSP 손실 함수 :




- 입력 : BERT는 트랜스포머 인코더를 포함한다
- 해당 문장을 처리하기 위해 문장 앞에는 CLS 토큰, 마지막에는 SEP 토큰을 추가한다
→ [CLS]BERT는 트랜스포머 인코더를 포함한다[SEP]
- [MASK] 토큰 적용 방법은 텍스트 토큰 중 15%에 해당하는 단어를 대상으로 마스킹을 수행
 - 이 중 80%는 [MASK] 토큰으로 대체
 - 10%는 어휘 사전에 존재하는 무작위 단어로 변경
 - 나머지 10%는 실제 토큰을 그대로 사용
- BERT는 사전 학습을 수행한 후, 미세 조정 기법을 통해 다양한 자연어 처리 작업에 적용할 수 있다

- Ex) 문장 분류, 감성 분석, 질문 응답, 기계 번역 등
- 미세 조정 과정에서는 해당 작업에 맞는 계층을 추가하고 손실 함수를 정의해 학습한다
- 분류 문제에서는 일반적으로 [CLS] 토큰 벡터를 사용하고, 각 토큰마다 예측이 필요한 경우에는 모든 토큰 벡터를 사용한다

BART

- Bidirectional Auto-Regressive Transformer
- 2019, 메타의 FAIR 연구소에서 발표한 트랜스포머 기반의 모델
- BERT의 인코더와 GPT의 디코더를 결합한 시퀀스 - 시퀀스(Sequence-to-Sequence, Seq2Seq) 구조
- 노이즈 제거 오토인코더(Denoising Autoencoder)로 사전 학습된다
- 오토 인코더 사전 학습 방법
 - 입력 데이터에 잡음 추가
 - 잡음이 없는 원본 데이터를 복원하도록 학습하는 방식
- BART의 사전 학습 방법 :




- 노이즈 제거 오토인코더 사용 : 입력 문장에 임의로 노이즈 추가, 원래 문장을 복원하도록 학습

- 노이즈가 추가된 텍스트를 인코더에 입력 → 원본 텍스트를 디코더에 입력해 디코더가 원본 텍스트를 생성할 수 있게 학습하는 방식
- → 이를 통해 문장 구조와 의미를 보존하며 다양한 변형을 학습할 수 있다
- 이 구조는 입력 문장에 큰 제약 없이 노이즈 기법을 적용할 수 있으므로 더 풍부한 지식 습득이 가능하다

• BART 모델의 특징

- 인코더를 사용함으로써 순방향 정보만 인식할 수 있는 GPT 단점 개선
- 양방향 문맥 정보를 반영할 수 있음
- 디코더를 사용함으로써 문장 생성 분야에서 뛰어나지 않았던 BERT 단점을 개선
- 문장 생성 또는 번역 작업에 적합하다
- 문장 독해, 문서 요약, 질의응답 등에 있어 높은 성능을 보인다

• BART 모델의 구조 :

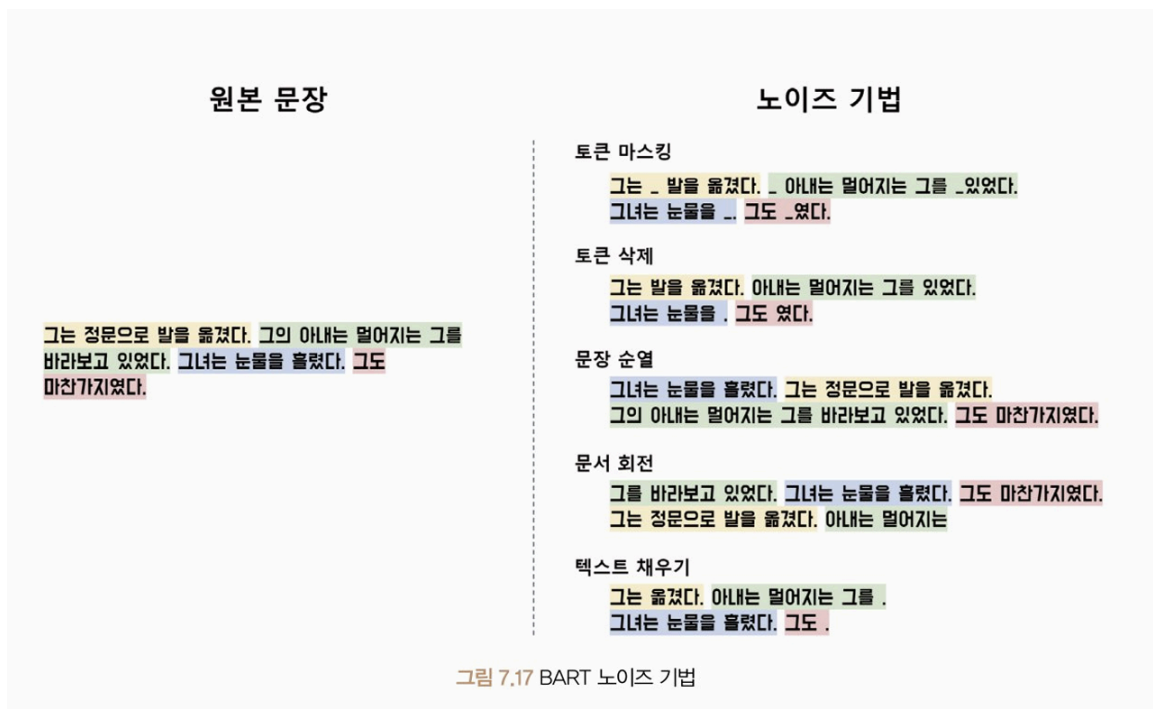


- 전반적으로 트랜스포머와 유사한 구조
- 차이점 :
 - 트랜스포머는 인코더와 디코더의 모든 계층에서 어텐션 연산을 수행

- BART는 인코더의 마지막 계층과 디코더의 각 계층 사이에서만 어텐션 연산을 수행
 - ⇒ 정보 전달을 최적화, 메모리 사용량 감소 가능
- BART의 인코더 : 입력 문장의 각 단어를 임베딩
- 여러 층의 인코더를 거쳐 마지막 계층에서는 입력 문장 전체의 의미를 가장 잘 반영하는 벡터가 생성
- 이렇게 생성된 벡터는 디코더가 출력 문장을 생성할 때 참고됨
- 디코더의 각 계층에서는 이 벡터와 이전 계층에서 생성된 출력 문장의 정보를 활용해 출력 문장을 생성

사전 학습 방법

- BERT의 마스킹된 언어 모델링(MLM) 이외에도 다양한 노이즈 기법을 사용
- 문장의 일부를 가리는 토큰 마스킹 기법, 토큰 삭제, 문장 교환, 문장 회전, 텍스트 채우기 기법이 사용됨



[Token Masking]

- MLM과 동일한 기법
- 입력 문장의 일부 토큰을 마스크 토큰으로 치환하는 방법
- 문장 내에서 어떤 단어가 중요한 역할을 하는지 학습 가능하다
- 입력 문장의 문맥을 이해하고 문장 내에서 중요한 정보를 추출하는 능력이 향상

[Token Deletion]

- 입력 문장의 일부 토큰을 삭제
- 마스킹과 달리 삭제된 위치를 맞춰야 함
- 중요하지 않은 정보를 필터링하여 학습 효율 증가
- 예측 시간 단축 및 모델 성능 향상

[Sentence Permutation]

- 마침표 기준으로 문장을 나누고 순서를 섞음
- 모델은 원래 순서를 맞추도록 학습
- 문장 내 단어 연결 구조를 더 잘 파악하게 됨
- 입력 문장의 순서가 바뀌어도 처리 가능

[Document Rotation]


- 문서의 시작 위치를 임의의 토큰으로 회전
- 문장 순서는 유지되며, 시작 토큰만 변경
- 모델이 문서의 시작점을 인식하도록 유도

[Text Infilling]

- 여러 개의 토큰을 하나의 구간(span)으로 묶어 마스크 토큰으로 대체
- 구간 길이는 0부터 임의의 값까지 설정 가능
- 푸아송 분포($\lambda=3$)로 구간 길이 계산
- 길이가 0인 경우는 변경된 토큰 없음
- 연속된 마스크 토큰을 복구해야 하며, 마스킹되지 않은 토큰도 구분해야 함
- 누락된 단어 예측을 통해 입력 문장을 더 잘 이해하게 됨

미세 조정 방법

- 인코더와 디코더를 모두 사용하는 구조이므로 미세 조정 시 각 다운스트림 작업에 맞게 입력 문장을 구성해야 한다
- 즉 인코더와 디코더에 다른 문장 구조로 입력한다
- BART의 다운스트림 작업별 미세 조정 방법 :



[문장 분류 작업]

- 입력 문장을 인코더와 디코더에 동일하게 입력하고

- 디코더의 마지막 토큰 은닉 상태를 선형 분류기의 입력값으로 사용
- BERT의 CLS 토큰과 유사한 역할 → BART는 전체 입력과 어텐션 연산이 적용된 은닉 상태를 사용

[토큰 분류 작업]

- BART는 입력 문장을 인코더와 디코더에 동일하게 입력한다
- 디코더의 각 시점별 마지막 은닉 상태를 토큰 분류기의 입력값으로 사용
- 전체 입력과 디코더의 각 시점별 은닉 상태와의 어텐션 연산을 수행한다

[문장 생성]

- BART는 트랜스포머 디코더를 사용하므로 BERT가 해결하지 못 한 문장 생성 작업 수행이 가능하다
- 입력값을 조작해 출력을 생성하는
 - 추상적 질의응답(Abstractive Question Answering)과
 - 문장 요약(Summarization)과 같은 작업에 적합하다
- 이러한 작업들은 BART의 사전 학습 방식과 유사하기 때문에 뛰어난 성능을 보인다
- 이러한 학습 방법을 통해 BART는 문장의 의미를 파악하고 이를 기반으로 문장을 새롭게 생성하는 능력을 갖게 된다
 - ex) 기계 번역 작업
 - 사전 학습된 인코더에 기계 번역을 위한 인코더를 추가해 작업 수행
 - 이 때 추가된 인코더는 기존의 단어 사전을 사용하지 않아도 된다
 - 디코더는 사전 학습된 가중치와 단어 사전을 사용한다

[학습 단계]

- 첫 번째 단계 :
 - 새로 추가된 트랜스포머 인코더의 가중치와
 - 위치 임베딩,
 - 첫 번째 인코더 층의 셀프 어텐션 입력 행렬 가중치만 학습
- 두 번째 단계 : 모든 신경망의 가중치를 작은 반복으로 학습


- 문장 내부의 토큰 사이 상관관계를 파악해 문장의 의미를 더욱 정확하게 이해할 수 있다
- 입력 문장의 전체적인 의미를 고려하므로 BART가 자연어 생성 분야에서 매우 효과적인 모델임을 보여준다

ELECTRA

- Efficiently Learning an Encoder that Classifies Token Replacements Accurately
- 2020년, 구글에서 발표한 트랜스포머 기반의 모델
- 입력 마스킹을 생성하는 대신 **생성자(Generator)**와 **판별자(Discriminator)**를 사용해 사전 학습을 수행
- ELECTRA의 사전 학습 접근 방식은 변환기 모델인 생성자와 판별자를 학습하므로 **생성적 적대 신경망(GAN)**과 유사한 방법으로 학습이 수행됨
- 생성 모델은 실제 데이터와 비슷하게 토큰을 생성해 다른 토큰으로 대체
- 판별 모델이 생성 모델이 만든 데이터와 실제 데이터를 입력 받아 어떤 데이터가 실제 데이터인지, 아니면 생성된 데이터인지 구분한다
- ELECTRA는 GAN을 사용해 학습하므로 이전 언어 모델보다 더 효율적인 학습이 가능하다
- → 대규모 데이터셋에서 모델을 더 빠르게 학습할 수 있다
- 생성 모델을 통해 토큰을 생성하므로 다양한 자연어 생성 작업에서 보다 자연스러운 문장을 생성한다
- BERT와 비교해보면 모델의 매개변수 수가 더 적다
- → 모델의 크기가 줄어들어 더 빠르게 실행 가능하고 더 적은 메모리를 사용한다

사전 학습 방법

- 생성자 모델과 판별자 모델은 모두 트랜스포머 인코더 구조를 따른다
- 생성자 모델 :
 - 입력 문장의 일부 토큰을 마스크 처리
 - 마스크 처리된 토큰이 원래 어떤 토큰이었는지 예측하며 학습
- 판별자 모델 :
 - 각 입력 토큰이 원본 문장의 토큰인지 생성자 모델로 인해 바뀐 토큰인지 맞히며 학습
- 이러한 학습 방법을 **RTD(Replaced Token Detection)**



◦ ELECTRA와 GAN의 차이점 :

- 생성자 모델은 BERT의 마스킹 언어 모델과 동일
: 입력 문장의 15%를 마스크 처리해 마스크 처리된 토큰이 원래 어떤 토큰이었는지 맞히며 학습
- 판별자 모델은 생성자 모델이 복원한 결과값을 받아 각 토큰이 원본 토큰인지 바뀐 토큰인지 판별
- 이 과정이 GAN과 유사하지만 몇 가지 차이점이 있다

항목	ELECTRA	GAN (Generative Adversarial Network)
기본 구조	생성자 + 판별자 구조	생성자 + 판별자 구조
토큰 처리 방식	생성자가 마스킹된 토큰을 예측하여 문장을 생성	생성자가 원본과 유사한 문장을 생성
정확한 예측에 대한 처리	정확히 예측된 토큰도 원본으로 간주	정확히 예측되어도 생성된 것으로 간주함
학습 입력	마스킹된 텍스트를 입력	무작위 노이즈 벡터를 입력

생성자 학습 방식	마스킹된 언어 모델을 기반으로 학습	노이즈 기반 생성
판별자 역할	각 토큰이 원본인지 생성된 것인지 판단	문장 전체가 실제인지 생성된 것인지 구분
학습 목표	토큰 단위로 세밀하게 구분 (더 정교한 학습 유도)	전체 문장의 구분에 초점
학습 난이도	판별자가 더 쉽게 구분 가능	생성자와 판별자가 경쟁하므로 학습이 더 어려움


- 생성 모델을 판별 모델의 크기를 1/2에서 1/4 크기로 바꿔 설정
 - 모든 가중치를 공유하는 대신 임베딩 계층의 가중치만 공유
 - → 이를 통해 판별 모델이 학습하기 적합한 생성 모델을 유지하면서도 가중치를 공유해 효율적으로 학습
- ELECTRA는 사전 학습이 완료되면 생성 모델을 사용하지 X, 오직 판별 모델만 사용해 다운스트림 작업을 수행
 - 판별 모델은 트랜스포머 인코더로 구성, BERT와 동일한 구조
 - 다운스트림 작업은 BERT와 동일한 방식으로 미세 조정한다

T5

- Text-to-Text Transfer Transformer
- 2019년 구글에서 발표한 자연어 처리 분야의 딥러닝 모델, 트랜스포머 구조 기반
- 인코더-디코더 모델 구조, 다양한 자연어 처리 작업에서 높은 성능을 보임
- **입력과 출력을 모두 토큰 시퀀스로 처리하는 텍스트-텍스트 구조**
 - 입출력의 형태를 자유롭게 다룰 수 있음
 - 모델 구조상 유연성과 확장성이 뛰어남
 - 새로운 자연어 처리 작업에서도 쉽게 적용 가능

사전 학습 방법

- 대표적인 학습 작업 : 문장 번역, 요약, 질의응답, 텍스트 분류 등



- 입출력이 토큰(텍스트) 시퀀스이기 때문에 입력과 출력 간의 관계를 더욱 세밀하게 다룰 수 있다
 - 사전 학습 후 미세 조정 단계에서 해당 작업의 데이터를 이용해 모델을 조정해 최적의 성능을 얻는다
- T5는 텍스트-텍스트 모델이므로 학습을 위한 데이터세트는 원본 문장과 대상 문장을 사용한다
 - **C4 데이터 세트**를 활용해 다양한 자연어 처리 작업을 수행할 수 있게 사전 학습 되었다
 - 사전 학습 방식은 **비지도 학습 방식**
 - 입력 문장의 일부 구간을 마스킹해 입력 시퀀스 처리
 - 출력 시퀀스는 실제 마스킹된 토큰과 마스크 토큰의 연결로 구성
 - 이때 문장마다 유일한 마스크 토큰을 의미하는 **센티널 토큰(Sentinal Token)**이 사용됨
 - 센티널 토큰 :
 - <extra_id_0>, <extra_id_0> 과 같이 0부터 99까지 100개의 기본값 사용
 - ex) '인코더-디코더 모델 구조'
 - '인코더'와 '디코더'를 마스킹해 처리할 경우
 - 입력 토큰의 센티널 토큰 : [<extra_id_0>,-,<extra_id_1>,모델 구조]

- 출력 토큰 : [인코더,<extra_id_0>,디코더,<extra_id_1>]

미세 조정 방법

- T5는 이러한 마스킹 토큰을 예측하는 것을 목적으로 사전 학습됨
- 사전 학습 완료된 후, 미세 조정을 통해 다양한 자연어 처리 작업을 수행한다
- T5의 미세 조정 방법은 **지도 학습 방식**으로 학습된다
- 번역, 언어 수용성, 문장 유사도, 문서 요약 등 다양한 작업에 활용 가능
- T5 모델의 입력과 출력은 텍스트 토큰들로 이뤄져 있으며
- 인코더-디코더 T5 모델에 입력된다
- 이 과정에서 문장이 인코딩되기 전에 작업 토큰을 문장 앞에 추가한다
- Ex)
 - 'translate English to German :'
 - 'summarize :'
- → 이러한 방식은 작업 토큰도 함께 학습해 다양한 자연어 처리 작업에서 높은 성능을 발휘하게 할 수 있다