

✓ BERT

BERT: 트랜스포머 기반 양방향 인코더를 사용하는 자연어 처리 모델

- 양방향 인코더: 입력 시퀀스를 양쪽 방향에서 처리하여 이전과 이후의 단어를 모두 참조하면서 단어의 의미와 문맥을 파악
- 대규모 데이터를 사용해 사전 학습되어 있으므로 전이 학습에 주로 활용
- 일부 또는 전체를 다른 작업에서 재사용해 적은 양의 데이터로도 높은 정확도 달성, 학습 시간 크게 단축
- 트랜스포머의 인코더 모듈만을 사용해 입력 문장을 처리

BERT에서 사용되는 트랜스포머 모듈




image.png

BERT의 사전 학습 방법


- 마스킹된 언어 모델링: 입력 문장에서 임의로 일부 단어를 마스킹하고 해당 단어를 예측
 - 입력 문장에서 누락된 단어 추론 가능
- 다음 문장 예측: 두 개의 문장이 주어졌을 때, 두 번째 문장이 첫 번째 문장 다음에 오는 문장인지 여부를 판단

- 두 문장 간의 관계 학습, 문장 간의 의미적인 유사성 파악

BERT 모델의 특수 토큰

- [CLS]: 입력 문장의 시작 부분에 추가된 토큰
 - 문장 분류 작업을 위한 정보 제공
 - 입력 문장이 어떤 유형의 문장인지 파악 가능
- [SEP]: 입력 문장 내에서 두 개 이상의 문장을 구분하기 위해 사용
 - 입력 문장을 두 개의 독립적인 문장으로 인식
- [MASK]: 입력 문장 내에서 임의로 선택된 단어를 가리킴
 - 주어진 문장에서 일부 단어를 가린 후 모델의 학습과 예측에 활용

BERT 모델의 입력 임베딩과 손실 함수



모델 실습


- bert-base-multilingual-cased: 다중 언어를 지원하며 대소문자를 유지하는 사전 학습된 모델
- do_lower_case: 소문자 유지 매개변수
 - False: 소문자로 변환하지 않게 함
 - True: 'APPLE'과 'apple'을 다른 단어로 인식
- RandomSampler: 데이터를 무작위로 샘플링, 학습에 적용
- SequentialSampler: 데이터를 고정된 순서대로 반환, 검증 및 평가 배치에 적용
- AdamW: Adam 최적화 함수에 가중치 감쇠를 추가한 변형된 경사 하강법 알고리즘

✓ BART

BART: BERT의 인코더와 GPT의 디코더를 결합한 시퀀스-시퀀스 구조


- 노이즈 제거 오토인코더로 사전 학습
 - 입력 데이터에 잡음 추가, 잡음이 없는 원본 데이터 복원

BART 사전 학습 시각화



- 입력 문장에 임의로 노이즈를 추가하고 원래 문장을 복원하도록 학습
- BERT가 인코더 학습 시 텍스트에 마스킹을 추가해 노이즈를 주는 방법과 GPT가 디코더 학습 시 다음에 등장할 단어를 예측하는 방법으로 간주 가능

BART 모델 구조



- 인코더의 마지막 계층과 디코더의 각 계층 사이에만 어텐션 연산 수행
- 인코더에서 입력 문장의 각 단어를 임베딩하고 여러 층의 인코더를 거쳐 마지막 계층에서 입력 문장 전체의 의미를 가장 잘 반영하는 벡터 생성

BART의 사전 학습 방법

- 다양한 노이즈 기법 사용
 - 토큰 마스킹: BERT에서 사용한 MLM과 동일, 입력 문장의 일부 토큰을 마스크 토큰으로 치환
 - 토큰 삭제: 입력 문장의 일부 토큰을 삭제
 - 어떤 위치의 토큰이 삭제되었는지도 맞춰야 함
 - 문장 순열: 마침표를 기준으로 문장을 나눈 뒤, 문장의 순서를 섞음
 - 모델은 원래의 문장 순서를 맞춰야 함
 - 문서 회전: 임의의 토큰으로 문서가 시작되도록 함
 - 모델은 문서의 원래 시작 토큰을 맞춰야 함
 - 텍스트 채우기: 몇 개의 토큰을 하나의 구간으로 묶고 일부 구간을 마스크 토큰으로 대체

BART의 미세 조정 방법

- 문장 분류 작업에서는 입력 문장을 인코더와 디코더에 동일하게 입력, 디코더의 마지막 토큰 은닉 상태를 선형 분류기의 입력값으로 사용
- 토큰 분류 작업에서는 입력을 인코더와 디코더에 동일하게 입력
- 추상적 질의응답과 문장 요약 같은 작업에 적합

모델 실습

- facebook/bart-base: BART 모델의 기본 버전
- BartForConditionalGeneration: BART 모델의 변형, 조건부 생성 작업에 특화
 - 입력 시퀀스로부터 출력 시퀀스를 생성하는 데 사용
- 루지 점수: 생성된 요약문과 정답 요약문이 얼마나 유사한지를 평가하기 위해 토큰의 N-gram 정밀도와 재현율을 이용해 평가하는 지표
 - ROUGE-1: 유니그램 사용 / ROUGE-2: 바이그램 사용 / ROUGE-N: N-gram 사용
 - ROUGE-L: 생성된 요약문과 정답 요약문 사이에서 최장 공통부분 수열(LCS) 기반의 통계 방식
 - ROUGE-LSUM: 텍스트 내의 개행 문자를 문장 경계로 인식, 각 문장 쌍에 대해 LCS 계산, union-LCS 값 계산
 - ROUGE-W: 가중치가 적용된 LCS 방법

✓ ELECTRA

ELECTRA: 생성자와 판별자를 사용해 사전 학습을 수행

- 변환기 모델인 생성자와 판별자를 학습하므로 생성적 적대 신경망(GAN)과 유사한 방법으로 학습 수행
- 대규모 데이터셋에서 모델을 빠르게 학습, 자연스러운 문장 생성 가능

ELECTRA의 사전 학습 방법

- 생성자 모델과 판별자 모델 모두 트랜스포머 인코더 구조를 따름
 - 생성자 모델: 입력 문장의 일부 토큰을 마스크 처리하고 마스크된 토큰이 원래 어떤 토큰이었는지 예측하며 학습
 - 판별자 모델: 각 입력 토큰이 원본 문장의 토큰인지 생성자 모델로 인해 바뀐 토큰인지 맞히며 학습(RTD)
- 생성자 모델이 원래 토큰을 정확히 예측한 경우, 생성된 토큰이 아닌 원본 토큰으로 인식
- 생성 모델과 판별 모델이 같은 개수의 계층으로 구성되어 있다면 가중치 공유 가능, 빠르게 학습
 - 가중치를 완전히 공유하면 성능이 너무 높아져서 판별 모델이 학습할 수 없게 됨
 - ELECTRA는 임베딩 계층의 가중치만 공유

모델 실습

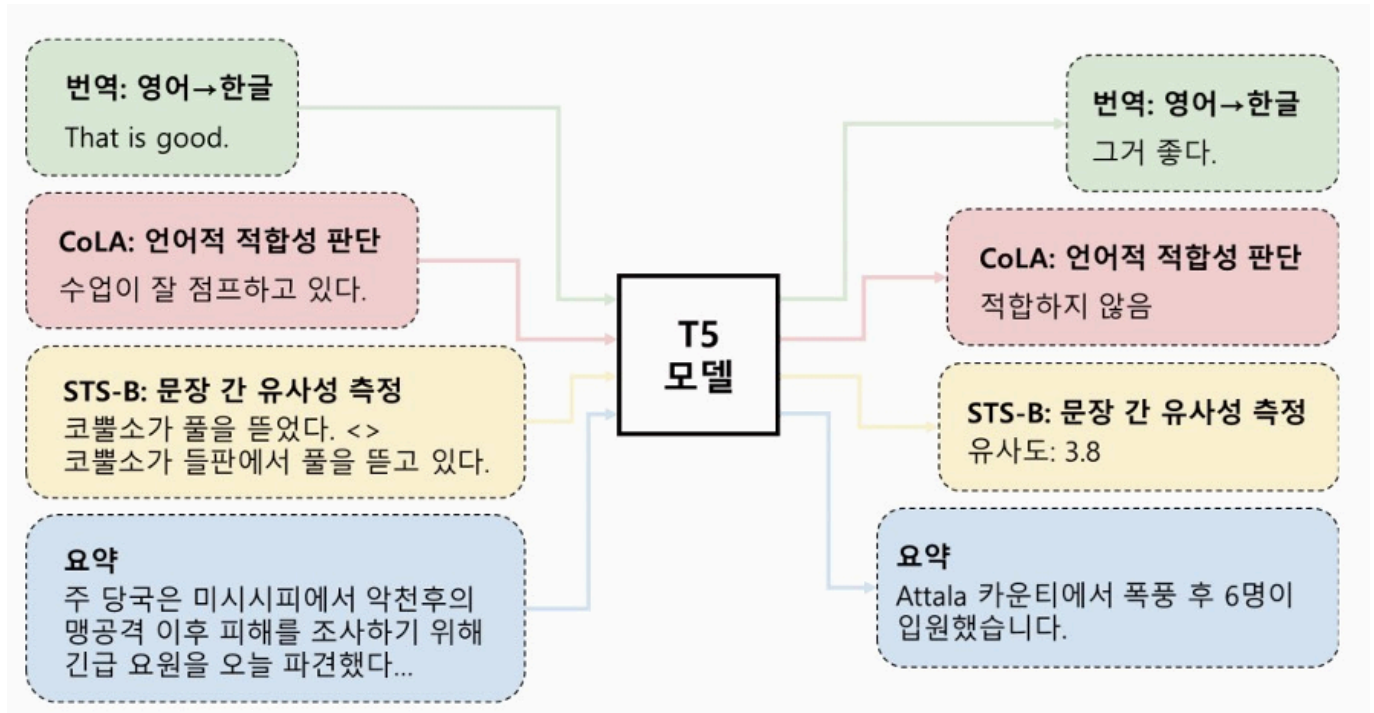
- monologg/koelectra-base-v3-discriminator: koelectra-base 모델의 판별 모델
- ElectraForSequenceClassification: ELECTRA 문장 분류 모델
- GLUE: 문장 수준 또는 문서 수준의 이해력을 평가하는 데이터셋

✓ T5

T5: 인코더-디코더 모델 구조를 바탕으로 다양한 자연어 처리 작업에서 높은 성능을 보이는 모델

- 입력과 출력을 모두 토큰 시퀀스로 처리하는 텍스트-텍스트 구조

T5 모델 학습 유형



- CoLA 데이터세트를 사용하면 문법적으로 허용 가능한 문장과 그렇지 않은 문장 구분 가능
- STS-B 데이터세트를 사용하면 문장 간 의미적 유사성 측정 가능
- 사전 학습 방식: 비지도 학습 방식으로 입력 문장의 일부를 마스킹해 입력 시퀀스를 처리, 출력 시퀀스는 실제 마스킹된 토큰과 마스크 토큰의 연결
- 문장마다 센티널 토큰 사용: 문장마다 유일한 마스크 토큰
- 미세 조정 방식: 지도 학습 방식으로 학습

모델 실습

- T5Tokenizer: 사전 학습된 토크나이저를 불러와 전처리를 수행
- t5-small: T5 모델의 기본 버전
- T5ForConditionalGeneration: T5 모델의 미세 조정을 위한 클래스
- shared 임베딩 함수: 인코더와 디코더 함수에 사용되는 토큰 임베딩으로 서로 공유되게 설정
- 생성 메서드: 입력 문장에 대한 요약문을 생성
- 반복 페널티: 중복 토큰 생성을 제어하는 값
- 길이 페널티: 생성된 시퀀스 길이에 대한 보상을 제어

